

Resumen Final de los trabajos grupales

A lo largo de las tres primeras semanas del curso se desarrollaron dos líneas de trabajo en paralelo, aplicando y comparando algoritmos de aprendizaje supervisado y no supervisado sobre dos datasets clásicos: Titanic (supervivencia) y Breast Cancer Wisconsin (diagnóstico). En ambos casos, el trabajo de las tres semanas fue consolidado en un solo notebook, de modo que las fases se ejecutan de forma continua y comparable entre sí. Además, que no se obtuvieron correcciones en las tres semanas.

1. Titanic - Predicción de Supervivencia

Las tres semanas se unificaron en un único notebook (UIDE_G1_TOTAL_Titanic), estructurado en tres fases secuenciales que reutilizan el mismo preprocesamiento y partición train/test.

- **Semana 1 (LR, KNN, NB):** la Regresión Logística mejorada fue el mejor modelo ($AUC \approx 0.84$), con alta interpretabilidad vía coeficientes. La ingeniería de variables resultó más determinante que el ajuste de hiperparámetros.
- **Semana 2 (DT, RF, SVM, RNA):** Random Forest mejorado logró la mejor generalización; SVM (kernel RBF) igualó a RF en AUC (0.86). La RNA (TF/Keras) mostró curvas de entrenamiento estables.
- **Semana 3 (PCA + Clustering):** reducir a 2 componentes solo retuvo 55.6% de varianza, por lo que PCA empeoró a los 7 algoritmos sin excepción. El mejor clasificador global fue SVM sin PCA (Test Acc 82.7%, AUC 85.2%). En clustering, K-Means/GMM con $K=2$ fue lo óptimo, pero con separación moderada (Silhouette 0.31), reflejando que la supervivencia no es una estructura puramente geométrica de los datos.

Conclusión del módulo: no hay un modelo universal la ingeniería de características y el preprocesamiento fue importante en las tres semanas.

2. Cáncer de Mama - Diagnóstico Benigno/Maligno

De igual forma, el trabajo de las tres semanas sobre el dataset Wisconsin Diagnostic se unificó en un solo notebook (UIDE_G1_TOTAL_Cancer), manteniendo las mismas 7 variables seleccionadas más 2 variables de ingeniería a lo largo de todas las fases, y priorizando el FNR (falsos negativos) como métrica clínica clave.

- **Semana 1 (LR, KNN, NB):** tras eliminar multicolinealidad severa, los modelos alcanzaron resultados cercanos a benchmarks de referencia (XGBoost/RF 97.5%) usando solo 9 variables, validando la selección de features.
- **Semana 2 (DT, RF, SVM, RNA):** la RNA baseline fue el mejor resultado (Test Acc 97.4%, Recall 100%, AUC 99.7%, FNR 0%); SVM baseline también destacó (Test Acc 96.5%, AUC 99.3%). Los outliers afectaron más a SVM y RNA que a los modelos basados en árboles.
- **Semana 3 (PCA + Clustering):** Regresión Logística sin PCA fue el mejor clasificador (Test Acc 96.5%, AUC 99.6%); la RNA con PCA alcanzó Recall 100%. A diferencia de Titanic, el clustering con K-Means ($K=2$) sí replicó bien el diagnóstico clínico (Silhouette 0.43, accuracy referencial 88.6%).

Conclusión del módulo: el preprocesamiento y la ingeniería de variables fueron determinantes, y el FNR se mantuvo como la métrica prioritaria por su implicancia clínica (un maligno no detectado es el error más costoso).