

Informe Técnico de Proyecto

Optimización de Mantenimiento Predictivo Industrial mediante Aprendizaje por Refuerzo (DQN)

Integrantes: César Nelson Abarca Araujo · Iván Fernando Vega Salazar · Santiago Paúl Guallichico Ati

1. Descripción de la problemática

En la gestión de activos e ingeniería industrial, la transición de un mantenimiento reactivo o programado por calendario hacia un mantenimiento predictivo es clave para maximizar la rentabilidad y evitar paradas de línea costosas. Se diseñó una planta industrial simulada (entorno Gymnasium personalizado) compuesta por 4 máquinas operando en paralelo, cada una sujeta a un desgaste estocástico continuo (distribución exponencial). En cada paso de tiempo, un agente debe decidir si continuar la operación normal o intervenir con mantenimiento preventivo sobre la máquina más desgastada, buscando evitar averías catastróficas sin incurrir en intervenciones innecesarias (sobremantenimiento).

2. Justificación del algoritmo seleccionado: DQN

El estado del entorno es un vector continuo de 4 dimensiones (salud de 0% a 100% por máquina). Los métodos tabulares vistos en clase — Q-Learning, SARSA y Monte Carlo — requieren un espacio de estados discreto y finito; aplicarlos aquí exigiría discretizar la salud en rangos, perdiendo precisión y sin garantía de que la tabla resultante capture bien la dinámica continua del desgaste. Se seleccionó Deep Q-Network (DQN) porque es, en esencia, Q-Learning — misma actualización basada en la ecuación de Bellman, misma política ϵ -greedy con decaimiento — extendido con una red neuronal como aproximador de función, que permite operar directamente sobre el estado continuo sin discretización. DQN se mantiene así dentro de la familia de Q-Learning permitida por el enunciado, resolviendo su limitación tabular para este problema en particular.

3. Aplicación del método de Aprendizaje por Refuerzo

- Estado: vector continuo de 4 valores — salud (0-100%) de cada máquina.
- Acciones: espacio discreto {0: operar sin intervenir, 1: solicitar mantenimiento sobre la máquina con mayor nivel de degradación}.
- Recompensa: +10 por máquina operativa en cada paso · +20 por mantenimiento preventivo oportuno ($5\% < \text{salud} \leq 20\%$) · -10 por mantenimiento innecesario ($\text{salud} > 20\%$) · -600 por avería / mantenimiento correctivo forzado ($\text{salud} \leq 5\%$).
- Entrenamiento: red neuronal de 2 capas ocultas (128, 128 neuronas), tasa de aprendizaje 5×10^{-4} , búfer de repetición de 100,000 transiciones, tamaño de lote 128, factor de descuento $\gamma = 0.99$, exploración ϵ decreciente de 1.0 a 0.02 durante el 40% de los 80,000 pasos totales de entrenamiento. Evaluación: 500 eventos con política determinística (greedy).


4. Resultados obtenidos (evaluación de 500 eventos)

Métrica	Sin RL (política fija c/12 pasos)	Con RL (agente DQN)
Mantenimientos preventivos	15	35
Mantenimientos correctivos (averías)	28	11
Ratio de mantenimiento preventivo (PMR)	34.9 %	76.1 %
Disponibilidad de planta	94.6 %	98.0 %
Recompensa acumulada	2980.0 pts	13790.0 pts


El agente DQN redujo las averías de 28 a 11 eventos (-60.7 %) y multiplicó la recompensa acumulada por $\sim 4.6\times$ (2980 $\rightarrow$ 13790 pts) frente a la política tradicional, además de subir el ratio de mantenimiento preventivo de 34.9% a 76.1% y la disponibilidad de planta de 94.6% a 98.0%. Esto evidencia que el agente aprendió a intervenir de forma

anticipada en la zona de alerta (5%-20% de salud) con mayor frecuencia y precisión que la política tradicional, evitando buena parte de los colapsos no programados. El modelo se entrenó con semilla fija (reproducible) y selección automática del mejor punto de convergencia (EvalCallback), en vez de usar el estado final de la red al azar.

Gráficos del entrenamiento



Evolución de salud de las 4 máquinas y recompensa acumulada, con RL (izquierda) y sin RL (derecha).



Comparación directa de la recompensa acumulada: con RL vs. sin RL.

5. Participación y aportes de cada integrante

- César Nelson Abarca Araujo — Elaboración del informe técnico y validación de resultados (verificación de métricas y consistencia de la comparación RL vs. sin RL). Además, revisó la coherencia de la función de recompensa frente a la problemática planteada y verificó la reproducibilidad de los resultados.
- Santiago Paúl Guallichico Ati — Entrenamiento del agente DQN y ejecución de las simulaciones (con y sin RL). Configuró y ajustó los hiperparámetros del modelo, ejecutó múltiples corridas para verificar la estabilidad de la convergencia, y generó los videos de evaluación utilizados como evidencia de los resultados.
- Iván Fernando Vega Salazar — Creación del video explicativo del proyecto. Estructuró el guion narrativo, seleccionó los fragmentos más representativos de las simulaciones grabadas, y editó el material audiovisual final para presentar con claridad la problemática, la solución desarrollada y los resultados obtenidos.

6. Enlaces del proyecto

Repositorio GitHub (notebook ,Código Fuente, videos): <https://github.com/cnabarca/Maestria-IA-UIDE/tree/main/6.%20Aprendizaje%20por%20refuerzo/Trabajo%20final/Tarea%20G5>

Video explicativo (YouTube): <https://youtu.be/KVnCbGmeCCY?si=l7f5ivUA-A9raL0W>